Hito 1 - Avance del proyecto integrador

Predicción de churn en telecomunicaciones

26.54

de cada 100 clientes se dieron de baja

Integrantes:
Patricio Rodriguez Delgado
Romina Enriquez Martinez
Anais Huayhuapuma De la cruz

Ruta del avance

1

Comprensión del negocio

Problema, decisión, KPI y variable objetivo

Parte 1

2

Comprensión de los datos

Dataset, diccionario y carga reproducible

Parte 1

3

Preparación de los datos

Calidad, atípicos y decisiones de limpieza

Parte 2

4

Plan de modelado

Técnicas, alternativas y cómo se evaluarán

Parte 3

Primeras fases del ciclo CRISP-DM. Esta presentación muestra el avance del proyecto.

Problema y decisión

26.54

de cada 100 clientes se dieron de baja

1 869 de 7 043 clientes del dataset

1. **Captar sale más caro**
   Conseguir un cliente nuevo cuesta más que conservar a uno actual (supuesto del negocio, a validar con la empresa).
2. **Retención sin criterio**
   El presupuesto se reparte sin saber quién está por irse.
3. **Gasto mal dirigido**
   Se gasta en clientes que igual se quedarían y se deja de atender a quienes sí se van.

Datos del cliente
contrato, servicios y pagos

→

Riesgo de baja
el modelo estima la probabilidad

→

Lista priorizada
de mayor a menor riesgo

→

Promoción
la campaña llama primero a los de más riesgo

Pregunta analítica: ¿qué clientes tienen más probabilidad de darse de baja? · Unidad de análisis: un cliente por fila · Decide: el área de retención

KPI y variable objetivo

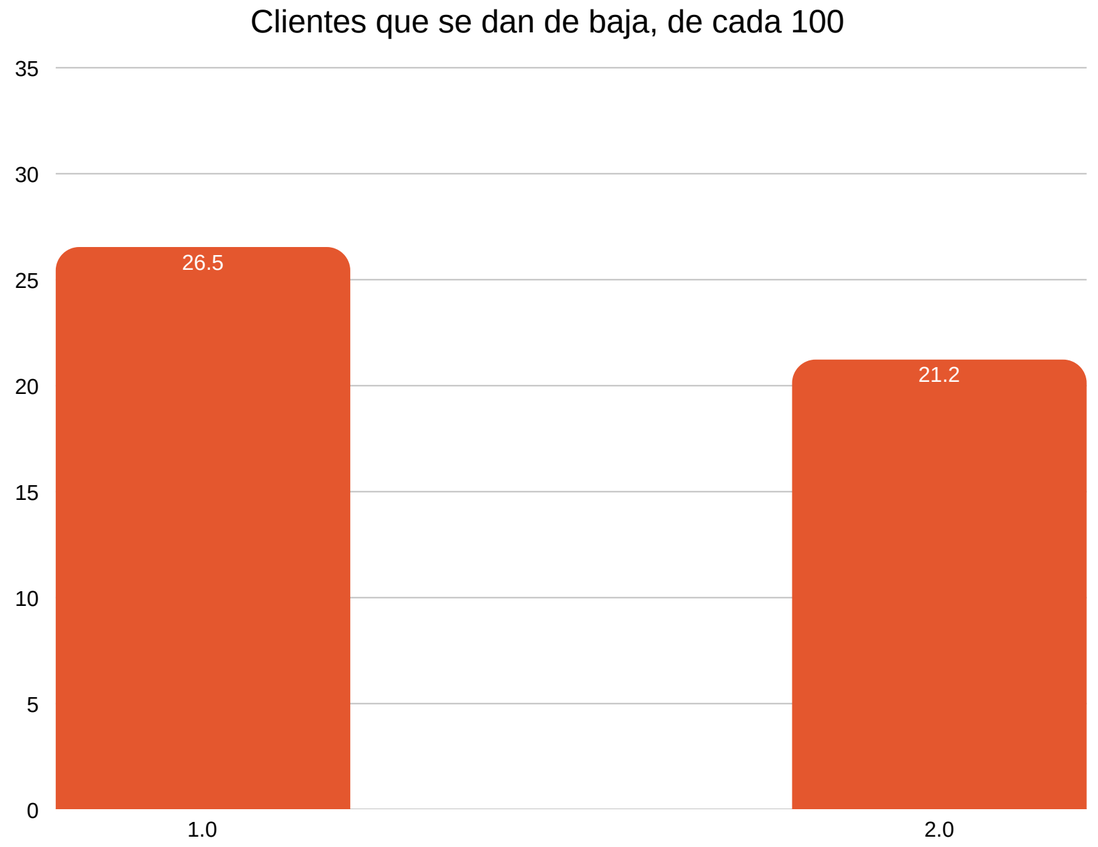
FÓRMULA

Clientes que se dieron de baja ÷ total de clientes × 100

1 869 ÷ 7 043 × 100 = 26.54

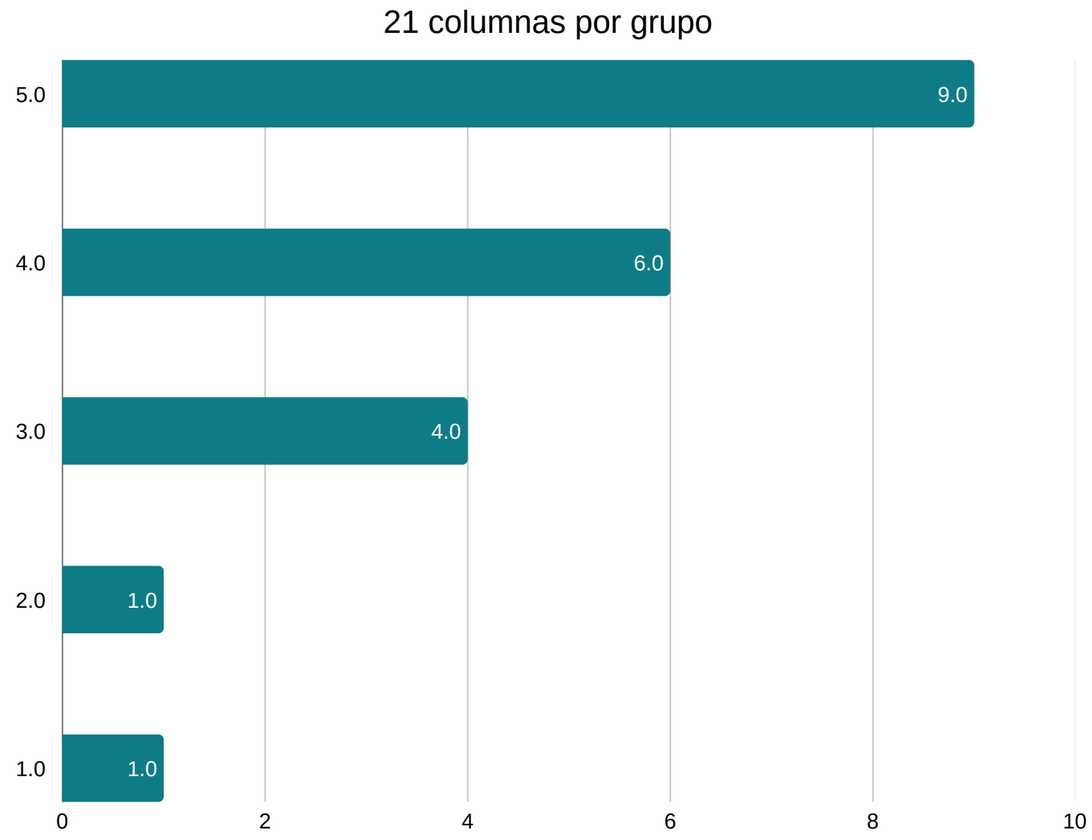
La meta de ≈ 21.23 es una referencia del equipo (una quinta parte menos que hoy). La empresa debe confirmarla.

Variable objetivo: Churn (sí / no), ya viene en los datos. 5 174 clientes siguen y 1 869 se dieron de baja. Unidad de análisis: un cliente por fila.



Los datos del proyecto

Fuente	Telco Customer Churn (Kaggle, BlastChar), datos de ejemplo de IBM
Obtención	22/10/2026
Tamaño	7 043 filas y 21 columnas
Momento	Foto de un solo momento, sin fechas
Licencia	Datos © autores originales; uso académico



Carga reproducible en Colab

REPOSITORIO

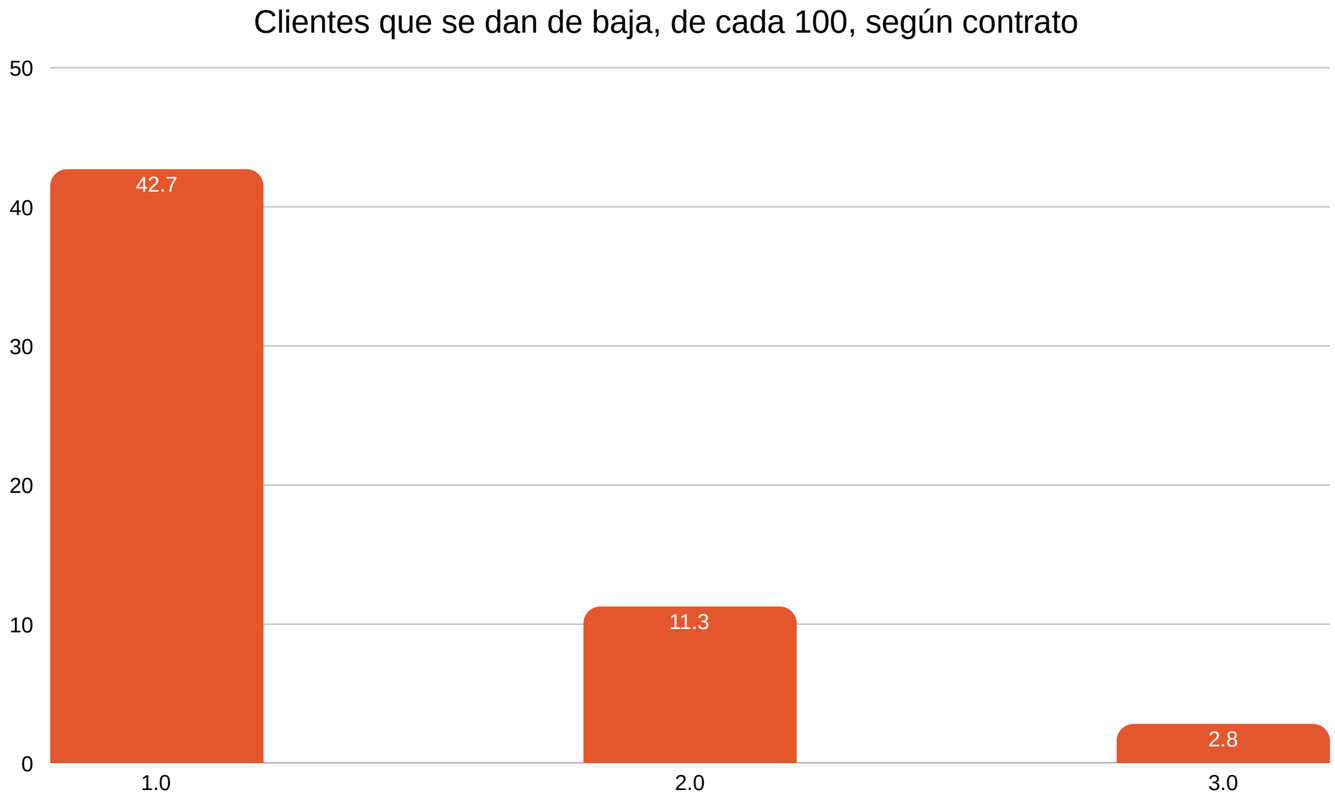
```
repositorio/
├── data/
│   ├── WA_Fn-UseC_-Telco-Customer-Churn.csv
│   └── diccionario_datos.md
├── notebooks/
│   ├── 01_carga_datos.ipynb
│   └── 02_comprension_preparacion.ipynb
├── informes/
│   ├── Ficha_Proyecto_CRISP-DM_Hito1.docx
│   ├── Canvas_Proyecto_Datos_Hito1.docx
│   └── Plan de modelado.docx
└── README.md
```

RESULTADO DEL CUADERNO 01

```
Datos cargados correctamente
Código de verificación coincide: True
Filas y columnas: (7043, 21)
Churn  No: 5174   Yes: 1869
Línea base (tasa de fuga): 26.54
```

Semilla fija (42), rutas relativas y ejecución de inicio a fin en Colab, sin pasos manuales. El cuaderno 02 valida cada columna contra el diccionario.

Primera mirada a la fuga



88.6

de cada 100 bajas son de clientes con contrato mes a mes

Ese grupo es el 55.0 de cada 100 clientes. La fuga se concentra en un solo tipo de contrato.

Fuente: dataset Telco Customer Churn, 7 043 clientes. Cálculo propio.

Calidad de los datos

0 celdas vacías a simple vista en las 21 columnas

11 casillas en blanco, todas en la columna TotalCharges

0 clientes repetidos: cada código de cliente es único

0 valores atípicos (regla del rango intercuartil) en tenure, MonthlyCharges y TotalCharges

Hallazgo: las 11 casillas en blanco son de clientes con 0 meses de antigüedad: aún no recibían su primera factura y ninguno se dio de baja. Hay muchos clientes nuevos (0 a 12 meses: 2 186) y muy antiguos (61 a 72 meses: 1 407); no se elimina a ninguno.

Decisiones de preparación

Qué encontramos	Qué decidimos	Por qué
11 casillas en blanco en TotalCharges (guardada como texto)	**Poner 0, pasarla a número y conservar a los 11 clientes**	Aún no recibían factura (0.16 de cada 100 clientes)
«No internet service» y «No phone service» (2 208 filas)	**Convertirlas en «No»**	Esa información ya está en InternetService y PhoneService
Respuestas Sí / No y la columna Churn	**Convertirlas a 1 y 0**	Los modelos trabajan con números
Valores atípicos: 0	**No eliminar ninguno**	No hay valores extraños en los datos
La fuga no sube de forma pareja con la antigüedad ni con los servicios	**Crear n_servicios, grupo_antiguedad y pago_automatico**	Resumen de la vinculación con la empresa y de la forma de pago
Identificador y datos personales	**Dejar fuera customerID, gender y SeniorCitizen**	gender y SeniorCitizen se guardan solo para revisar sesgos
Hay que probar el modelo con datos que no vio	**Partición 80 / 20 estratificada, semilla 42 (5 634 y 1 409 clientes)**	El escalado y la codificación se aprenden solo con entrenamiento

Cada decisión se aplica en el cuaderno 02_comprension_preparacion, dentro del repositorio.

Técnicas candidatas

PRINCIPAL

Regresión logística

Sesión 9

Calcula la probabilidad de que cada cliente se dé de baja. Es la técnica base y se explica fácil a un directivo.

COMPARACIÓN

Clasificadores clásicos

Sesión 10

Capturan relaciones no lineales, como el pico de fuga con 3 servicios (44.92 %). Se comparan con la logística con los mismos datos.

APOYO

Regularización

Sesión 5

Controla variables muy relacionadas (antigüedad y cargos) y ayuda a elegir cuáles de las 20 variables pesan en la baja.

SEGUNDA FAMILIA

Supervivencia

Hito 2

Usa los meses de antigüedad como tiempo hasta la baja: dice cuándo se va el cliente, no solo quién.

Conexión con la pregunta: las cuatro ayudan a estimar quién tiene más riesgo de darse de baja y cuándo.

Alternativas que descartamos

Técnica	Por qué no la usamos
Regresión lineal	Predice cantidades. Nuestra variable es sí o no.
Series temporales	Los datos no tienen fechas.
Inferencia causal	No hay una intervención ni un grupo de comparación en los datos.
Clustering	Agrupa sin usar la respuesta y nosotros sí tenemos Churn; solo serviría de apoyo para describir perfiles.
Reducción de dimensionalidad	Con 20 variables interpretables se perdería explicabilidad.
Reglas de asociación y recomendación	No hay compras ni valoraciones de productos.

Cómo vamos a evaluar

PARTICIÓN

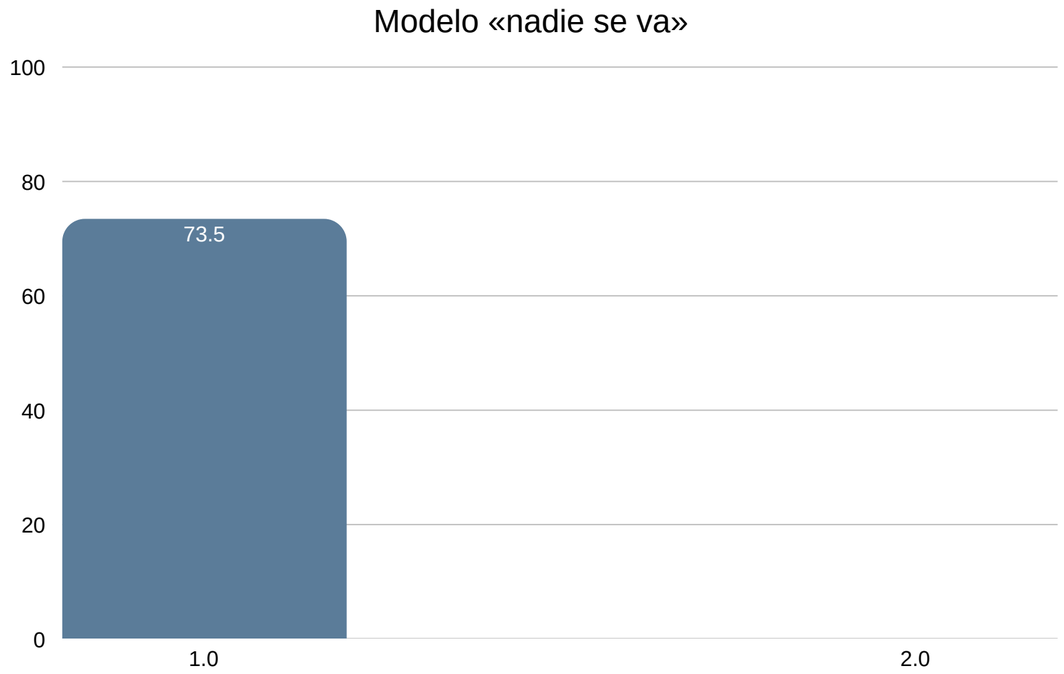
80 de cada 100 clientes para entrenar y 20 para probar (5 634 y 1 409), con la misma proporción de bajas. Semilla fija 42.

VALIDACIÓN

Validación cruzada de 5 partes solo dentro del entrenamiento. El grupo de prueba se usa una sola vez, al final.

MÉTRICAS

Recall: de los que sí se van, cuántos detectamos. Precisión: de los que marcamos, cuántos sí se iban. También F1, AUC y lift en el 10 % de mayor riesgo.



Un modelo que dice que nadie se va acierta 73.46 de cada 100 y no detecta ninguna baja. Por eso el modelo debe superar esa línea base en recall y AUC.

Qué significa para el negocio

LO QUE YA TENEMOS

- Un problema claro: 26.54 de cada 100 clientes se dan de baja
- Datos documentados y preparados (cuadernos 01 y 02), sin descartar clientes
- Un plan de modelado con técnicas, alternativas y métricas

LO QUE SIGUE

- Entrenar y comparar los modelos
- Evaluarlos con recall, precisión y AUC
- Entregar a retención la lista de clientes con más riesgo de irse

Lectura de negocio: el riesgo se concentra en clientes con poca antigüedad (47.44 % de fuga en los primeros 12 meses) y contrato mes a mes (88.6 de cada 100 bajas): ahí empezaría la retención. Meta de referencia: bajar de 26.54 a ≈ 21.23.